


Knowledge PTalk

Kiến trúc tri thức · Độ phủ · Phương pháp định lượng

Báo cáo kỹ thuật — Lớp tri thức đồng hành học bài (RAG companion)

2026-06-23



1.852 bài companion · 6 môn · lớp 4-9 · CTST/KNTT/CD
anchor 97.0% · guard 98.1% · rò rỉ nguồn 0 · P95 <370ms

Contents

1 Tóm tắt	2
2 Kiến trúc hạ tầng	2
3 Hai lớp tri thức	2
4 Hệ thống “hiểu ý định” trong câu hỏi	2
5 Độ phủ tri thức	3
6 Phương pháp định lượng	3
6.1 Backtest neo & guard (quy mô)	3
6.2 Backtest “scenario kiến thức” (chất lượng nội dung)	4
6.3 Refactor an toàn (parity)	4
7 Kết quả & lộ trình	5

1 Tóm tắt

PTalk là **bạn đồng hành học bài** (không phải hỏi-đáp mở): bám đúng bài/trang SGK học sinh đang học để *giảng · gợi mở · luyện tập · đọc thuộc*, sạch nguồn, độ trễ thấp, và *từ chối khi ra ngoài bài* thay vì đoán. Báo cáo này mô tả (i) kiến trúc tri thức hai lớp, (ii) cách hệ thống **hiểu ý định** trong câu hỏi, (iii) **độ phủ** hiện tại, và (iv) **phương pháp định lượng** dùng để kiểm chứng chất lượng trước khi đưa lên production.

Chỉ số	Giá trị	Ghi chú
Bài companion (:Lesson)	1.852	6 môn, lớp 4-9
Lớp nền (:KnowledgeChunk)	25.259	17.078 production-ready
Anchor (đường thiết bị)	97.0%	backtest 81 quyển, ~40k ca
Guard (từ chối ngoài bài)	98.1%	
Rò rỉ nguồn thật	0	“204 cruft” = false-positive
Độ trễ P95	193-368 ms	serve path Gemma-free

Table 1: Bảng số liệu tổng quan (đo thực, 2026-06).

2 Kiến trúc hạ tầng

RAG là **microservice nội bộ** (cổng 8888), *không* expose trực tiếp ra ngoài: thiết bị đi qua nginx-gateway tới các app thoại (ptalk_v1/v2/eldercare), app thoại mới gọi RAG nội bộ.




Figure 1: Topology runtime (đối chiếu docker ps/ss/nginx). Serve path **Gemma-free**; Gemma chỉ dùng lúc build/ingest + endpoint kiểm duyệt.

3 Hai lớp tri thức

Tri thức tổ chức 2 lớp: **lớp nền** (RAG rộng, dùng cho duyệt/phân tích & fallback) và **lớp companion** (:Lesson — bộ não đồng hành mà chatbot dùng chính).

4 Hệ thống “hiểu ý định” trong câu hỏi

Câu hỏi được hiểu theo **nhiều tầng tín hiệu**, tất cả *Gemma-free* ở đường serve (độ trễ <1ms cho phần định tuyến). Thông tin thiết bị (lớp, bộ sách, môn, *bài/trang đang học*) là đầu vào hạng nhất.

Ba câu hỏi cốt lõi mà hệ trả lời:




Figure 2: Hai lớp tri thức. Companion :Lesson là đơn vị đồng hành; lớp nền cấp dữ liệu & fallback.




Figure 3: Pipeline hiểu ý định + định tuyến (retrieve()). “Biết người dùng muốn gì” = kết hợp **ngữ cảnh thiết bị** (current lesson/trang) + **phân loại ý định bằng embedding** (giảng/đọc/luyện) + **tín hiệu cấu trúc** (bài/trang/tập), neo về đúng :Lesson.

- “*Học sinh đang ở bài nào?*” — từ current_lesson/trang (thiết bị gửi) hoặc tên bài nêu trong câu; nếu mơ hồ thì dùng content-vector (mô tả nội dung → ra bài), có ngưỡng chặn đoán bừa.
- “*Muốn làm gì với bài đó?*” — *giảng* (explain), *đọc thuộc* (recite), hay *luyện tập* (practice) — phân loại bằng độ gần ngữ nghĩa (BGE) + regex, không cần LLM.
- “*Có nằm ngoài phạm vi không?*” — nếu không neo được bài và không đủ tín hiệu, hệ **từ chối** (guard) thay vì bịa.

5 Độ phủ tri thức

6 Phương pháp định lượng

Mọi thay đổi đều **backtest-gated**. Có hai cấp đo:

6.1 Backtest neo & guard (quy mô)

Mỗi quyển sinh ~500 câu *giọng học sinh thật* (Gemma) phủ các chiều {current_lesson, tên-bài, trang+tập, practice, recite, content-only} + ~15% *adversarial guard* (chitchat,




Figure 4: Độ phủ companion theo môn (tổng **1.852** bài) và số bài đã *enrich* theory (giàu hơn). KHTN gần trọn (523/542); Toán đang nâng theo schema v2; xã hội/văn dùng theory nền.

Môn	Bài	Enrich	Thành phần thể
KHTN	542	523	giảng + luyện
Toán	537	17	giảng + luyện (+ phương pháp v2)
Lịch sử	253	0	giảng + luyện
Địa lí	246	0	giảng + luyện
GD&ĐT	147	0	giảng + luyện
Ngữ văn	127	0	giảng + luyện + đọc thuộc (pilot)
Tổng	1.852	540	1.852 có giảng+luyện; 5 có đọc thuộc

Table 2: Độ phủ chi tiết. Lớp nền bổ trợ: 25.259 chunk, 3.405 concept, 418 tác phẩm.

trang ngoài sách, bẫy từ, lạc đề, bài-ngoài-sách). Chấm tự động:

Metric	Ý nghĩa	Kết quả (81 quyển)
anchor_at_1	neo đúng bài (đường thiết bị)	97.0%
guard_accuracy	ngoài bài → từ chối đúng	98.1%
source_cruft_real	rò rỉ "vietjack/lời giải"	0
error_count	lỗi runtime	0
latency P95	độ trễ	193-368 ms
volume collision t1/t2	nhầm tập 1/2	0 (toan8: 96.4/98.8)

Table 3: Metric backtest quy mô. "204 cruft" từng báo là *false-positive* do keyword "giáo viên" (từ vựng hợp lệ); verify Neo4j 1.852 chunk: rò rỉ nguồn thật = 0.

6.2 Backtest "scenario kiến thức" (chất lượng nội dung)

Khác cấp trên (chỉ đo neo), cấp này dùng **LLM-judge** chấm *đúng kiến thức*: với mỗi bài, Gemma sinh kịch bản học tập grounded trên theory → companion trả lời → judge chấm knowledge_correct (0-2 so với theory), hallucination (bịa ngoài theory), intent_ok, real_cruft.

6.3 Refactor an toàn (parity)

Lỗi RAG được tách monolith → packages/ (knowledge_core + retrieval + rag_router) với **characterization test** + **parity** đối chứng thin-server vs monolith:




Figure 5: Điểm scenario-kiến-thức theo môn. Văn vốn tốt (theory grounded). Enrich nâng KHOA HỌC rõ (KHTN 0.74→0.81); Toán cần schema v2 (ví-dụ-tự-tính làm tăng hallucination — đang tinh chỉnh).




Figure 6: Enrich KHTN (trước→sau): % trả lời đủ kiến thức tăng (75→83), hallucination giảm (18.8→10.4). Validate scale: khtn6 KNTT 0.785, khtn8 CTST 0.770 — recipe khoa học nhất quán.

7 Kết quả & lộ trình

Đã đạt: companion 6 môn / 1.852 bài (đã promote prod, kèm fix chuẩn-hoá en-dash + endpoint kiểm duyệt); enrich KHOA HỌC toàn bộ (knowledge↑, hallucination↓, nhất quán); refactor thin-server (parity 100%); Dashboard *Lesson Card explorer* (/kg-companion).

Đang/sẽ làm: (1) tinh chỉnh enrich *Toán* (schema v2: phương-pháp thay ví-dụ-tự-tính, cấm bịa số) rồi scale; (2) làm giàu đọc-thuộc (recite) cho Văn; (3) deploy Dashboard companion view; (4) tích hợp client gửi đủ current_lesson/trang+tập (điều kiện đạt anchor 97%).

Số liệu đo thực 2026-06 trên Neo4j edu & backtest 81 quyển. Mọi thay đổi backtest-gated, sạch nguồn (0 rò rỉ thật).

Trường so khớp	Kết quả	
intent.tier	144/144	100%
intent.work_name	144/144	100%
context (anchored)	139/139	100%
unit tests (knowledge_core)	97 passed	golden snapshot

Table 4: Behavior-equivalence: thin-server (từ packages/) giống monolith **byte-for-byte**.